NMS 없이 실시간: DETR → RT-DETR

Carion et al., ECCV 2020 (arXiv:2005.12872)
Lv et al., CVPR 2024 (arXiv:2304.08069)

세트 예측이 정확도와 속도를 동시에 얻는 구조적 이유

① 문제 — NMS의 딜레마

두 임계값이 정확도와 시간을 반대 방향으로 움직인다
(논문 Table 1 · T4 TensorRT FP16)

conf 0.001 → 0.05
AP 52.9 → 51.2 NMS 2.36 → 1.06 ms
IoU 0.5 → 0.8
AP 52.1 → 52.8 NMS 2.24 → 2.46 ms

YOLO는 보통 NMS 시간을 제외한 모델 속도만
보고한다 → RT-DETR은 NMS 플러그인까지 포함한
end-to-end benchmark를 새로 세웠다(§3.2).

② 방법 — 세 번의 이동

(1) 중복 억제를 학습으로 (DETR §3.1)
헝가리아리안 최적 양자택일 매칭 →
NMS 없이 중복이 구조적으로 불가
매칭 비용=확률 / 손실=로그 우도
박스 손실=스케일 불변 GIoU + L1

(2) 컴퓨트를 설계로 (RT-DETR §4.2)
인코더가 GFLOPs 49%인데 AP는 11%
→ AIFI(S5만, 400토큰) + CCFF(conv 융합)

(3) 초기화를 품질로 (RT-DETR §4.3)
U=‖P-C‖를 손실에 → 분류·위치 일치 피처
Prop both 0.30% → 0.67%, AP 47.9 → 48.7
※ 랭킹은 그대로(분류 점수 기준)

③ 결과 — 정확도와 속도를 함께

	DETR	FRCNN+	RT-DETR
AP	42.0	42.0	**53.1**
AP_S	20.5	26.6	**34.8**
AP_L	61.1	53.4	**70.0**
params	41M	42M	**42M**
FPS	28	26	**108**

동일 파라미터(41M vs 42M)에서 AP 동급,
대신 AP_S -5.5 · AP_L +7.8로 성질이 뒤집힘.
RT-DETR은 DINO-Deformable 대비 +2.2 AP·21× FPS.

※ 조건부 비교: 입력 640×640(72ep) vs 800×1333(500ep),
하드웨어·정밀도 상이 → 절대값 비교 아님

④ 우리의 실험 (자체 실측·합성 데이터)

· 인코더 변형 A~E 지연 순서를 논문과 동일하게 재현:
A < D_S5 < E < B < D < C
· attention 토큰 8배 → 시간 42.3배(이론 64배)
8400 vs 400 토큰 = 441배 토큰 쌍 차이
· NMS 딜레마 두 방향 재현(conf↑/IoU↑)
· uncertainty 단독 최적화 퇴화 해 정량화:
s 0.90→0.690, q 0.20→0.693(서로 만남)
분류 손실 병행 시 0.794/0.793(품질이 확신 추종)

⑤ 한계 — 배운 것

· 소형 객체는 여전히 약점: AP_S 34.8
(YOLOv8-L 35.3 대비 -0.5, R101도 -0.9)
멀티스케일 특징을 쓰되 전역 attention을 S5에
제한한 설계의 대가(논문은 원인을 단독 입증 안 함)
· 49/11은 2차 통계(RT-DETR←Lin et al.←Deformable)
· 138%·120%는 상대 개수 차이지 %p 개선이 아님
· selection≠objective: uncertainty는 손실을 바꿈
· 논문은 2D COCO만 평가 → 3D 확장 미검증

⑥ 학습 흐름 · 다음

D1 MAE → D2 BEiT/SimMIM → D3 iBOT/DINOv2
→ D4~6 DeepSeek(V2/V3/R1)
→ D7 DETR + RT-DETR 심화 (96.6%)
→ D8 RT-DETR 본문 (97.0%)

산출물: 심화자료 16종 · 데모 4종 · 차트 22종
논문 대조 오류 0건

다음: GLIP+SAM → CLIP → LLaVA(2일) → VL-JEPA
병행: 3D 트랙 (DETR3D→PETR→StreamPETR→Sparse4D)

중복 제거를 학습으로 · 컴퓨트를 설계로 · 초기화를 품질로 옮기면 실시간과 정확도를 함께 얻는다