Post-Training Language Models: Three Ways to Say "Follow the Preference" — RLHF · DPO · GRPO

Ouyang et al. 2022 (InstructGPT) · Rafailov et al. 2023 (DPO) · Shao et al. 2024 (DeepSeekMath §4.1, GRPO)

Written as an autonomous paper-diary session · **2203.02155** (NeurIPS 2022) · **2305.18290** (NeurIPS 2023 Oral) · **2402.03300** (GRPO 원전)
모든 식·표·수치는 두 식 HTML(ar5iv/arXiv) 원문 직독으로 검증 — **factsheet_posttraining.md** 참조 · 논문 ID abs 재검증 완료 ("ID 검증 원칙")

INTRODUCTION

OR ABSTRACT

동기 — 대규모 언어모델은 다음 토큰 예측이라는 단일 통계적 목적으로 학습되지만, 이 목적은 "사람이 원하는 답"과 동일하지 않다. InstructGPT는 이 격차를 명시적으로 지목했다: **"aligning with user intent on a learned reward model while staying computationally feasible and predictable"**(§1). 본 포스터는 사후강화학습(post-training)의 3편 — 명시적 RM+PPO(RLHF), 재매개화에 의한 직접 선호최적화(DPO), critic 없는 그룹상대 정책 최적화(GRPO) — 이 **같은 KL-제약 선호최대화 문제에 대한 3가지 판단**임을 대조한다.

2022 InstructGPT · RLHF 원형 › **2023** DPO · 정책 = 암묵보상 › **2024** GRPO · critic 없는 PPO

85 ± 3%	61 / 57%	46.8→51.7	3 논문
175B InstructGPT > GPT-3 175B 선호율 (§4)	DPO vs PPO · TL;DR 승률 GPT-4 평가 (§6.2)	GRPO · MATH 상승폭 (DeepSeekMath §4.2)	2203.02155 · 2305.18290 · 2402.03300 abs 검증

COMMENTARY — *세 논문은 서로 다른 해법을 내놓았지만 문제 정식화는 하나로 수렴한다. 선호 데이터 $y_w > y_l$을 **어디에 적용하는가**(보상모델 vs 정책손실), **어디에 KL을 걸리는가**(보상항 vs 손실표), **value를 누가 대신하는가**(critic 모델 vs 그룹 통계) — 이 세 축이 사후강화학습 2년(2022→2024)의 구조적 계보를 결정한다.*

OBJECTIVES

연구 목적 3제

O1 정합(Alignment) — InstructGPT: 인간 의도에 맞추되 계산 가능성·예측 가능성을 유지하는 3단 레시피(SFT→RM→PPO)의 확립 (§1, §3).

O2 경제성(Efficiency) — DPO: 보상모델 피팅·온라인 샘플링·하이퍼파라미터 튜닝이라는 RLHF의 3대 부담을 재매개화로 제거(초록, §6.1).

O3 확장성(Scalability) — GRPO: 정책과 맞먹는 크기의 value/critic 모델을 그룹 통계로 대체해 RL을 대형모델에 맞춘다(§4.1.1–4.1.2).

COMMENTARY — *세 목적은 교대로 상대를 비판한다: RLHF의 비용을 DPO가 지적하고, DPO의 오프라인 한계를 GRPO가 온라인 RL 선으로 되돌린다. 심층적으로 보면 ***O1→O3는 "표현" → "손실" → "샘플링"의 관점 이동***이며, 어느 하나도 이전 단계의 수치적 정상성을 부정하지 않는다 — 동일 기준선 위에서의 판단 변경이다.*

METHOD I · INSTRUCTGPT

2203.02155

pipeline
식(1)·식(2)
§3 §4

레시피 — 고정 환경은 배질(bandit)

프롬프트 제시 → 응답 생성 → RM 보상(§3.5). Steps 2–3을 반복 수집한다.

SFT 시연 13k › **RM** 비교 33k › **PPO** 프롬프트 31k

항목	값 (원문)
라벨러	contractor ~40명 (§3.4)
모델	1.3B / 6B / 175B — GPT-3 아키텍처
SFT	**16 epochs** · 코사인 LR · dropout 0.2
RM	**6B만** — 175B RM은 불안정(부록 C.2)
라벨러 동의	72.6% · hold-out 77.3%

$$\text{loss}(\theta) = -\frac{1}{C(K,2)} \cdot E_{(x,y_w,y_l)}[\log \sigma(r_\theta(x,y_w) - r_\theta(x,y_l))]$$

식(1) — 보상모델 손실. K=4..9의 (K choose 2) 비교를 배치 1단위로.

$$\text{objective}(\phi) = E_{(x,y)}[r_\theta(x,y) - \beta \log(\pi_{RL}(y|x)/\pi_{SFT}(y|x))] + \gamma E_{\text{pretrain}}[\log \pi_{RL}(x)]$$

식(2) — PPO-ptx. γ=0 순수 PPO · γ>0이 PPO-ptx.

결과 — 진실성: TruthfulQA 참·정보성 회답 **약 2×** (§4.4). 폐쇄도메인 환각 **21% vs 41%** (절반 이하, §4.3). 독성 **~25% 감소** (§4.5). SFT 기본선 대비 승률 **73.4%** (T0 26.8% / FLAN 29.8%) — 실용성 1.3B 모델도 175B GPT-3를 능가(§1).

COMMENTARY — *식(2)의 γ항은 ***공개 NLP(SQuAD·DROP·HellaSwag·WMT-FR) 성능 저하 — 이른바 alignment tax — 를 되돌리는 안전판***이다(§4.2). 또한 RM에 per-token KL(SFT 대비)을 심어(식 2 중간항) ***보상모델 과최적화(overoptimization)를 완화***한다. RLHF가 "RL이라는 형식"보다 ***제약의 배치***를 설계의 핵심으로 본다는 점이 이 시절의 지적 유산이다.*

METHOD II · DPO

2305.18290

derivation
식(4)~식(7)
Theorem 1

분할함수를 죽이는 3식 — 정책이 곧 암묵적 보상

식(4) 도출된 목적의 수렴값 → 식(5) 재매개화 → 식(6)에서 **Z(x) 소멸**:

$$\pi_r(y|x) = \frac{1}{Z(x)}\pi_{ref}(y|x)\exp(r(x,y)/\beta) \quad\cdot\quad r(x,y) = \beta\log(\pi_r(y|x)/\pi_{ref}(y|x)) + \beta\log Z(x)$$

식(4), 식(5) — Bradley-Terry 사교(예3)의 보상을 정책비율로 재표현.

$$\mathbf{L_{DPO}(\pi_\theta;\pi_{ref}) = -E[\log \sigma(\beta\log(\pi_\theta(y_w|x)/\pi_{ref}(y_w|x)) - \beta\log(\pi_\theta(y_l|x)/\pi_{ref}(y_l|x)))]}$$

식(7) — 분할함수가 소멸(식6)하며 RL 없는 이항분류 손실로 수렴.

기울기 해설: σ항이 **암묵적 보상이 잘못 매긴 예에 큰 가중**을 실어 상승시킨다 — 이 가중을 떼면(또는 상수 페널티로 두면) LM 퇴화가 관찰된다(§5.1). **Theorem 1**: 등가클래스의 모든 보상은 이 재매개화로 표현된다 — 일반성 손실 0 (§5.1).

COMMENTARY — *DPO의 지적 위치는 ***"RLHF의 사용이 낭비가 아니라 인프라"***라는 두뇌였다: Reward pred. fitting → sampling → tuning의 3단 인프라가 사라지므로 ***동일 6B 규모에서 학습이 안정적·훨씬 가볍다***. 대가는 샘플링 문맥이 학습 내로 등장하지 않는다는 것 — 온라인 갱신이 필요한 문제는 GRPO에게 넘겨질 분기를 선언한 셈이다.*

METHOD III · GRPO

2402.03300 §4.1 · 원전

critic → 그룹통계
식(2)~식(4)
Alg. 1

PPO는 살아 있되 critic을 유리 위에 올려놓지 않는다

문제 — PPO의 value/critic은 **정책과 맞먹는 크기**의 별도 모델(메모리·계산 부담) + RM은 **마지막 토큰만** 보상하므로 토큰별 value 학습이 어렵다(Fig. 4). KL 항은 PPO의 per-token 식(2)를 그대로 유지(InstructGPT → Ouyang 계승):

$$r_t = r_\phi(q, o_{\le t}) - \beta\log(\pi_\theta(o_t|\ldots)/\pi_{ref}(o_t|\ldots))$$

식(2) — DeepSeekMath §4.1. InstructGPT의 per-token KL과 동일 계통.

질문 q → **그룹 $\{o_1 \ldots o_G\}$ 샘플** → **mean(r)·std(r) 정규화 → $\hat{A}_{i,t}$**

$$\hat{A}_{i,t} = \tilde{r}_i = (r_i - \text{mean}(r_{1..G}))/\text{std}(r_{1..G})$$

§4.1.2 — outcome supervision. value/critic 학습이 불요 · 그룹 상대평가는 "비교로 학습되는 RM의 성격과 정합"(§4.1.1).

$$J_{GRPO}(\theta) = E[(1/G)\Sigma_i (1/|o_i|)\Sigma_t \{\min[\rho\hat{A}_{i,t}, \text{clip}(\rho, 1-\varepsilon, 1+\varepsilon)\hat{A}_{i,t}] - \beta D_{KL}[\pi_\theta\|\pi_{ref}]\}]$$

식(3) — KL을 보상이 아니라 **손실에 직접**: advantage 계산을 단순하게 유지.

$$D_{KL}[\pi_\theta\|\pi_{ref}] = \pi_{ref}/\pi_\theta - \log(\pi_{ref}/\pi_\theta) - 1$$

식(4) — Schulman(2020)의 **불편추정량(always positive)**.

Algorithm 1 (Iterative GRPO) — 매 반복(I): π_ref 갱신 → M 스텝 × **μ회 GRPO** 업데이트 → RM은 **replay**로 계속 학습(§4.1.3).

COMMENTARY — *GRPO의 세부는 ***"advantage의 정의를 데이터 구조로 바꾼 것"***이다. critic이 였던 평행 추정을 ***같은 질문에 대한 G개 샘플의 z-정규화***로 대체하면, value 헤드라는 별도 개체가 프로그래밍적으로 소멸한다. 단순화가 아니라 ***불편추정량(식4)·클리핑 목적식(식3)·loss-side KL***의 조합으로 안정성을 재확보한다는 점이 원문의 설명 방식이다.*

RESULTS

DPO TABLE 1 · DEEPSEEKMATH §4.2

DPO · 인간 평가
Table 1

승률 (%)	DPO	SFT	PPO-1
Table 1 인간	**58**	43	17
GPT-4(Summary)	**47**	27	13
GPT-4–인간 동의율	**70**		인간–인간 65

61%	58%	128
TL;DR 승률 · T=0.0 (PPO 최적 57%, GPT-J 6B)	인간 DPO(T=.25) > PPO(T=0)	Best-of-128과 동등 이상(HH)

DEEPSEEKMATH 7B	GSM8K	MATH	CMATH
Base	64.2	36.2	—
Instruct	82.9	46.8	84.6
RL (GRPO)	**88.2**	**51.7**	**88.8**

GRPO RL 페이즈는 **영어 instruction 서브셋만**으로 진행 — out-of-domain(CMATH)까지 상승(§4.2). MATH **51.7%**를 외부 도구·투표 없이; 셀프커시스턴시(SC@64) **60.9%**. 사전학습은 DeepSeek-Coder-Base-v1.5 7B + **120B math tokens**(Minerva 대비 **7×**, OpenWebMath 대비 **9×**).

COMMENTARY — *두 결과표의 비교 기준은 다른 과제이지만 통제 매개는 같다 — ***유사 규모(≤6B / 7B), 동일 기본 모델, 상대법 평가***. DPO의 숫자는 ***샘플링 문맥 없이도 PPO에 필적하는 승률이 나온다***는 정상성 증명이고, GRPO의 숫자는 ***critic 없이도 RL 계열의 상승이 보존된다***는 정상성 증명이다. 즉 두 논문의 수치는 상대를 이기려는 계산이 아니라 서로 다른 갈래의 존재 근거로 읽는 것이 정확하다.*

SYNTHESIS

같은 문제 · 다른 구조

항목	INSTRUCTGPT	DPO	GRPO
보상모델	명시적 (6B)	**암묵적 (Thm. 1)**	명시적 — critic 없음
온라인 샘플링	필요	**불요**	필요 (그룹 G개)
KL 제약 위치	보상에 per-token	목적식 내장(식7)	**손실에 직접(식3)**
anchor 수치	85±3% 선호율	TL;DR 61 vs 57	MATH 46.8→51.7

대응 관계 — 선호 학습을 **오프라인 이진분류로 접은 갈래**(DPO) ↔ **온라인 RL은 살리되 critic 제거로 비용을 낮춘 갈래**(GRPO). DeepSeekMath의 통합 관점(§5.2.1): **RFT · DPO · PPO · GRPO는 전부 "직접 또는 단순화된 RL"**의 한 지점이다.

COMMENTARY — *관찰적으로 세 논문은 하나의 연속선 위에 있다: 명시적 RM+PPO가 기준선, DPO가 ***재매개화 정리***로 정책=보상의 등가성을 증명해 데스크톱 규모까지 끌어내리고, GRPO가 ***샘플 구조의 재정의***로 온라인 RL의 스케일 경제학을 회복한다. 이 분지는 DeepSeek-R1(2501.12948 · Day06 기록)의 규칙보상 GRPO로 연결 — 본 카드는 ***원전 DeepSeekMath §4.1 기준***으로 R1과의 중복을 피했다.*

CONCLUSIONS

1. 사후강화학습의 3편은 같은 KL-제약 선호최대화 문제의 **구조적으로 다른 3개 대안**이며, 어느 승자도 아니다 — DPO는 식(6)–(7)로, GRPO는 식(3)–(4)로, 각자 **죽여야 할 개체(critic, 분할함수)**를 지목했다.

2. 제약의 배치가 설계의 본질이다: KL이 보상에 있으면(식2) value의 학습 불안정성이 위임되고, 손실에 직접 있으면(식3) advantage가 단순해진다. DPO의 내장 KL은 이 논리의 극단(개체 0개)이다.

3. 실무적 종착점은 2025년 R1이다: 수학에 맞춘 상대 평가의 성공은 **검증 가능한 규칙보상**으로 확장되어 일반 추론에 이르며, 본 세션의 원전 우선 원칙은 이 연결을 팩트시트에 명문화했다.

COMMENTARY — *유식하게 말하면: 3편은 ***동일 목적식 위의 세 가지 설계 지점*** — 정규화항의 위치(KL), 보상의 존재론적 지위(명시/암묵), advantage의 데이터 출처(critic/그룹) — 을 어떻게 재배치했는가의 기록이다. 앞으로의 질문은 "RL을 떼어내는가"가 아니라 ***"어떤 통계량이 advantage를 잘 추정하는가"***로 이동하고 있다.*

REFERENCES

ABS 재검증 완료

1. Ouyang, L. et al. **"Training language models to follow instructions with human feedback."** NeurIPS 2022. **arXiv:2203.02155**
2. Rafailov, R. et al. **"Direct Preference Optimization: Your Language Model is Secretly a Reward Model."** NeurIPS 2023 (Oral). **arXiv:2305.18290**
3. Shao, Z. et al. **"DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models."** §4.1 (GRPO 원전). **arXiv:2402.03300**
4. DeepSeek-AI. **"DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning."** Day06 자율세션 기록. **arXiv:2501.12948**
5. Schulman, J. et al. **KL Divergence Approximation** (2020) — DeepSeekMath 식(4)의 불편추정량 출처.

ACKNOWLEDGEMENTS · CONTACT

SESSION META

방법 — 라이브러리니안 병렬 검증 3건이 타임아웃 → ar5iv·arXiv HTML 원문을 curl 직접 파싱(식(1)~(10)·2402 식(1)~(4)·Table 1 대조)으로 전환, **factsheet_posttraining.md**에 팩트시트 확립. QA(qa_poster.py) PASS 후 세로 A-series PDF·PNG 엑스포트.

인용 지표 — Semantic Scholar(2026-11-02): InstructGPT **25,614** · DPO **11,437** · DeepSeekMath **10,603** · 영향력 인용 2,541 / 2,369 / **3,104 — GRPO 원전이 1위**.

COMMENTARY — *Ack — 이 세션은 Paper-Diary 자율세션 시리즈의 일부로, 수치 검증 규약(ID abs 재검증 · 미검증 인용 배제 · 원문 태그 유지)을 준수했다. 다음 예약 세션: ***SparseDrive (2405.19620)*** 자율주행 E2E.*